PESQUISA EM ENGENHARIA DE SOFTWARE

Código gerado por agentes de IA: qualidade e taxa de correção

Um estudo GQM comparando commits de agentes de IA e de humanos, pareados dentro do mesmo repositório open-source do GitHub

Pedro Luiz Nato Silva
Pedro Henrique Barbosa Montandon de Araújo
Jonathan Sena da Silva
Murilo Andrade Machado
Matheus Ferreira Titton
Guilherme Gomes de Brites

Setembro de 2026

CONTEXTO

Agentes de IA já escrevem código em produção

GitHub Copilot | Cursor | Devin | Claude Code

932.791
pull requests de IA no dataset AIDev

116.211
repositórios GitHub com agentes

Um mesmo arquivo, hoje, mistura trechos de IA e humanos.

Fonte: Li, Zhang & Hassan (2026) — AIDev

PROBLEMA

Ainda não sabemos se esse código dura

⚠ Cerca de **40% do código gerado por IA** exige correções antes de ir para produção (Akbar & Anderies, 2025)

⚠ Commits de correção de bugs cresceram **6,1%** após a adoção de IA, enquanto a intensidade de revisão caiu **20,8%** (Ebiwonjumi et al., 2026)

⚠ A literatura **diverge** sobre complexidade e manutenibilidade do código de IA — resultados opostos entre estudos (Cotroneo et al., 2025; Jamil et al., 2025)

Falta medir isso commit a commit, dentro de um mesmo repositório — comparando agente e humano sob as mesmas condições.

OBJETIVO

Avaliar diferenças nas características do código — complexidade, manutenibilidade e taxa de correção — em função da autoria do commit, agente de IA ou humano, dentro de um mesmo repositório

Comparação pareada por commit, usando o dataset AIDev como base de seleção de repositórios

QUESTÕES DE PESQUISA

Quatro perguntas, um desenho pareado por commit

Q1 — COMPLEXIDADE

Commits de agentes de IA introduzem mais ou menos complexidade que commits humanos, no mesmo repositório?

Q2 — MANUTENIBILIDADE

Commits de agentes de IA deixam o código mais ou menos manutenível que commits humanos?

Q3 — ESTRUTURA E TAMANHO

Como o tamanho e a documentação do código variam entre commits de agentes de IA e humanos?

Q4 — TAXA DE CORREÇÃO

Com que frequência um trecho de IA precisa ser corrigido de novo, comparado a um trecho humano?

MÉTRICAS

O que medimos para responder cada pergunta

Q	Métricas-chave	Instrumento
Q1	Δ complexidade ciclomática · Δ vocabulário, volume, dificuldade e esforço (Halstead)	Radon (cc, hal)
Q2	Δ índice de manutenibilidade · % de commits que pioram ou cruzam para faixa crítica	Radon (mi)
Q3	Linhas lógicas e de comentário por commit · razão de documentação · arquivos/funções tocados	Radon (raw) + diff
Q4	Nº de commits subsequentes na mesma linha · tempo até 1ª correção · origem da correção	git blame / git log -L

LITERATURA

15 artigos mapeados às perguntas de pesquisa

Q1 · COMPLEXIDADE

Cotroneo et al. 2025 · Jamil et al. 2025 · Patel et al. 2024 · Guo et al. 2026 · Idrisov & Schlippe 2024 · Clark et al. 2024

Q2 · MANUTENIBILIDADE

Jamil et al. 2025 · Molison et al. 2025 · Guo et al. 2026 · Li, Mo et al. 2026

Q3 · ESTRUTURA E TAMANHO

Cotroneo et al. 2025 · Patel et al. 2024 · Idrisov & Schlippe 2024 · Li, Mo et al. 2026

Q4 · TAXA DE CORREÇÃO

Akbar & Anderies 2025 · Ebiwonjumi et al. 2026 · Przymus et al. 2025 · Molison et al. 2025 · Huang et al. 2026

FUNDAMENTAÇÃO E DATASET

Li, Zhang & Hassan 2026 (dataset AIDev) · Kitchenham, Pfleeger & Fenton 1995 (validade de métricas) · Ying, Towey & Zhang 2025 (taxonomia de avaliação)

METODOLOGIA

Seis etapas, do repositório à análise

1

Seleção de repositórios

Subconjunto do AIDev, Python, sem squash-merge, com mínimo de commits por grupo

2

Classificação de autoria

Bot conhecido, trailer Co-authored-by ou cruzamento com pr_commits do AIDev

3

Filtro de tamanho mínimo

Remove reformatação e commits triviais, com piso mínimo de linhas lógicas (LLOC)

4

Extração de métricas

Radon antes/depois do commit (cc, hal, mi, raw), restrita às funções tocadas

5

Rastreamento de correções

git blame / git log -L para localizar commits que corrigem as mesmas linhas

6

Análise estatística

Modelo misto por repositório, teste de Wilcoxon pareado e tamanho de efeito (Cliff's δ)

REFERÊNCIAS

Referências bibliográficas

1. Ying, Towey & Zhang (2025). IEEE COMPSAC.
2. Akbar & Anderies (2025). IEEE ICCTEIE.
3. Cotroneo, Improta & Liguori (2025). arXiv:2508.21634.
4. Jamil, Abid & Shamail (2025). IEEE/ACM MSR.
5. Ebiwonjumi, Ahakonye & Kim (2026). IEEE ICAIIC.
6. Idrisov & Schlippe (2024). Algorithms, 17(62).
7. Przymus, Fejzer, Narębski & Stencel (2025). arXiv:2504.03863.
8. Molison, Moraes, Melo, Santos & Assunção (2025). ESEM.
9. Huang, Jaisri, Shimizu et al. (2026). MSR '26.
10. Patel, Sultana & Samanthula (2024). IEEE BigData.
11. Guo, Zhou, Xu, Wang & Jia (2026). ACSTA.
12. Li, Mo, Zeng, Li & Ma (2026). ACM TOSEM.
13. Clark, Igbokwe, Ross & Zibran (2024). IEEE ICoSSE.
14. Li, Zhang & Hassan (2026). MSR '26 — dataset AIDev.
15. Kitchenham, Pfleeger & Fenton (1995). IEEE TSE.